

机器学习作业 3


2020 年 11 月 12 日

181860152 周宇翔

1.[20pts]Decision Tree

(1)

f 是 realizable 的



(2)

$$p_0 = 0.4, p_1 = 0.6$$

$$Ent(D) = -\sum_{k=0}^1 p_k \log_2 p_k$$

$$= -0.4\log_2 0.4 - 0.6\log_2 0.6 = 0.971$$

设两个 Feature 分别为 F_1, F_2 (F_1, F_2 就是 x_1, x_2 我后来才发现但是懒得改了 ovo)

$$Gain(D, F_1) = Ent(D) - 10 * \frac{1}{10} * 0 = 0.971$$

$$IV(a) = \log_2 10 = 3.32$$

$$Gain_ratio(D, F_1) = 0.292$$

$$\text{类似的 } Gain_ratio(D, F_2) = 0.292$$

但是如果把每个 feature 当作离散值的一个分类处理, 会导致虽然每个节点的纯度很高, 但是决策树的泛化能力很弱, 无法对新样本进行有效预测

因此我按照第 i 个分类的取值为 $(5 * i, 5 * (i + 1)], i = 0, 1, 2, \dots$ 进行处理

$$Gain(D, F_1) = Ent(D) - \frac{|D^4|}{|D|} Ent(D^4) - \frac{|D^6|}{|D|} Ent(D^6) - \frac{|D^8|}{|D|} Ent(D^8) - \frac{|D^9|}{|D|} Ent(D^9) - \frac{|D^{10}|}{|D|} Ent(D^{10})$$

$$= 0.97 - 0.4 * (-0.25\log_2 0.25 - 0.75\log_2 0.75) - 0.1 * 0 - 0.1 * 0 - 0.1 * 0 - 0.3 * (-0.33\log_2 0.33 - 0.66\log_2 0.66)$$

$$= 0.17$$

$$IV(F_1) = -0.4\log_2 0.4 - 0.3\log_2 0.3 - 3 * 0.1\log_2 0.1 = 2.05$$

$$Gain(D, F_2) = Ent(D) - \frac{|D^7|}{|D|} Ent(D^7) - \frac{|D^8|}{|D|} Ent(D^8) - \frac{|D^9|}{|D|} Ent(D^9) - \frac{|D^{10}|}{|D|} Ent(D^{10}) - \dots$$


$$= 0.97$$

$$IV(F_2) = -0.2\log_2 0.2 - 9 * 0.1\log_2 0.1 = 3.12$$

$$Gain_ratio(D, F_1) = \frac{Gain(D, F_1)}{IV(F_1)} = 0.083$$


$$Gain_ratio(D, F_2) = \frac{Gain(D, F_2)}{IV(F_2)} = 0.31$$

因此选取 F_2 作为分类标准



2.[20pts]Neural Network

(1)



(2)

可以, 因为在这个计算过程中始终只会有输入变量 X_1, \dots, X_d 的一次项存在, 不会产生交叉项, 高次项或者非线性项, 因此可以不用隐层表示


(3)

对于 Logistic Regression, 输入 $\mathbf{X} = X_1, \dots, X_d$

输出为 $z = \mathbf{w}^T \mathbf{X} + b$, 并用 sigmoid 函数 $y = \frac{1}{1+e^{-z}}$ 来将 z 值转化为一个接近 0 或 1 的 y 值

Logistic Regression 通过令 $(\mathbf{w}, \mathbf{b}) = \operatorname{argmin}_{\mathbf{w}, \mathbf{b}} \sum_{i=1}^d (\hat{y}_i - y_i)^2$ 来逼近 \mathbf{w} 和 \mathbf{b} 的最优解

在求解过程中使用梯度下降法, 梯度为 $\nabla f(\mathbf{w}) = X^T X \mathbf{w} - X^T \mathbf{y}$



在神经网络中, 我们如图考虑:

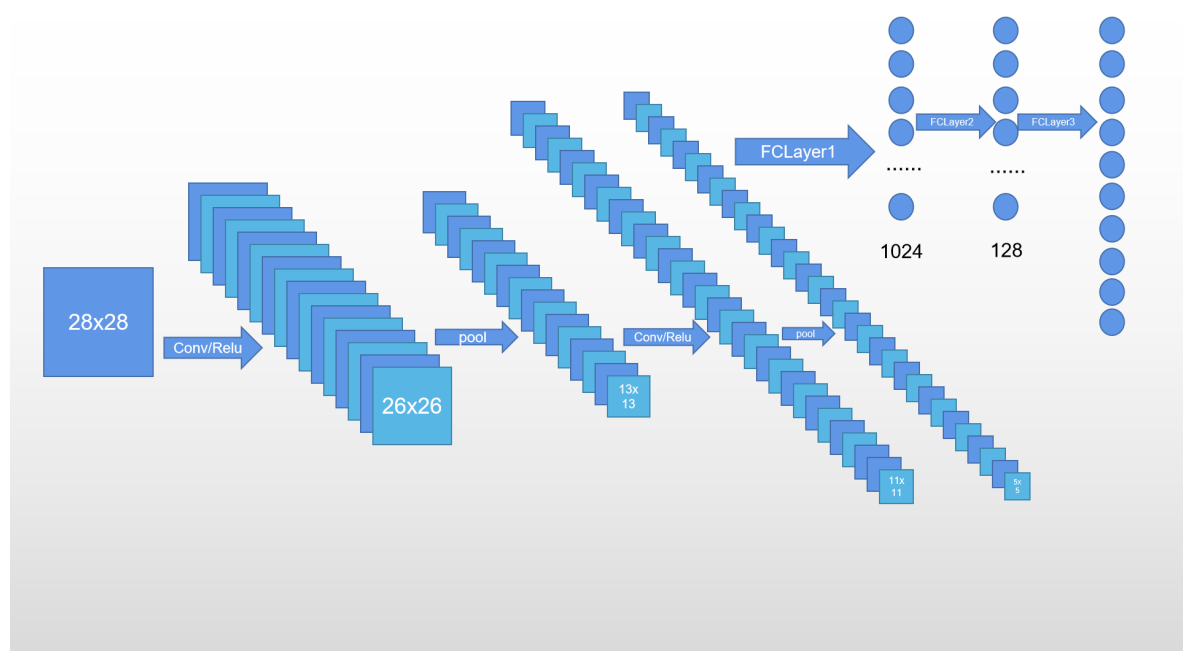
输出节点的输入为 $\sum_{i=1}^d X_i W_i$, 对应到对数几率回归中的 $w^T X$, 激活函数为 $y = f(\sum_{i=1}^d X_i W_i - \theta)$, 如果让 θ 对应到 $-b$, f 为 sigmoid 函数

则 $w^T X + b$ 可表示为 $\sum_{i=1}^d X_i W_i - \theta$

则此时的 y 对应到对数几率回归中的 y 值, 此时采用逆传播法, 通过最小化 $E_k = \frac{1}{2} \sum_{i=1}^d (\hat{y}_i^k - y_i^k)$ 来逼近最优解, 由于此时仍然对各系数取值采用梯度下降法进行调整, 因此若控制所有系数的学习率一致, 该神经网络学习的就是一个对数几率回归的模型

3.[60pts]Neural Network in Practice

(2)



(3)

选取 $\text{epochs} \in \{1, 2, 3, 4, 5, 6, 7, 8\}$, $\text{Learning Rate} \in \{0.001, 0.002, 0.003, 0.004, 0.005\}$

进行测试

具体数据见附表 `params2.txt`

综合 Accuracy, AverageLoss 以及 Epochs 考虑, 选取

Epochs=7, Learning Rate=0.002 进行作为该模型的参数

(4)

对于 `training_loss` 的变化, 我采用对每一批 (60 个) 数据都记录一次 loss 来刻画, 并使用

`matplotlib.pyplot` 来绘制图像

图大致如下, 具体可见附件 `training_loss.png`

